

Proyecto Semestral:

Predicción de Precio de Acciones de Apple, Tesla, Google, Microsoft y Amazon

Enzo Reyes Ibarra

COM4402 – Introducción a Inteligencia Artificial

Escuela de Ingeniería, Universidad de O'Higgins

21, diciembre, 2023

Resumen — En este trabajo, se abordó la tarea de predecir los precios de acciones de las empresas Apple, Microsoft, Tesla, Google y Amazon mediante el uso de una red neuronal recurrente (RNN) basada en capas de memoria a largo plazo (LSTM). La implementación de la red neuronal demostró ser exitosa, logrando predicciones precisas que capturaron patrones complejos y dependencias temporales en los datos históricos.

La elección de utilizar capas LSTM fue esencial, ya que permitieron a la red aprender y recordar patrones a largo plazo, característica crítica en el entorno financiero. La validación en un conjunto de prueba confirmó la capacidad del modelo para generalizar a nuevos datos, evitando el sobreajuste.

La aplicación del modelo a empresas tecnológicas diversas resaltó su versatilidad y adaptabilidad a diferentes contextos empresariales. Los resultados obtenidos sugieren que la red neuronal recurrente podría ser una herramienta valiosa en la toma de decisiones financieras, aunque se subraya la importancia de considerar estos resultados en conjunto con otras fuentes de información y análisis.

Aunque el trabajo ha proporcionado resultados prometedores, se identificaron áreas de mejora potencial, como la optimización de hiperparámetros y la exploración de arquitecturas más avanzadas. Esto abre la puerta a futuras investigaciones y refinamientos en la aplicación de inteligencia artificial en la predicción de precios de acciones.

I. INTRODUCCIÓN

En la era digital actual, la convergencia de la tecnología y la información ha dado lugar a avances significativos en campos tan diversos como la medicina, la educación, el deporte y las finanzas. Uno de los aspectos más destacados de esta revolución tecnológica es el auge de la inteligencia artificial (IA), y en particular el profundo impacto que tiene en la toma de decisiones predictivas en los mercados financieros. Este trabajo se centra en el mundo de la inteligencia artificial aplicada a la predicción de precios de acciones, centrándose en

algunas de las empresas más influyentes del panorama tecnológico, como lo son, Apple, Tesla, Google, Microsoft y Amazon.

En un entorno empresarial cada vez más dinámico y globalizado, la capacidad de anticipar las fluctuaciones en los precios de las acciones se ha convertido en un elemento crucial para inversores, analistas y entusiastas del mercado. Tradicionalmente, los modelos financieros han dependido de enfoques estadísticos y matemáticos convencionales, pero con la aparición de la inteligencia artificial, especialmente del aprendizaje profundo (deep learning), se ha abierto una nueva puerta en la predicción de precios.

Este trabajo explorará específicamente cómo los modelos de deep learning, específicamente redes neuronales recurrentes, pueden ser aplicados con éxito en la predicción de los precios de acciones de empresas tecnológicas líderes como las que estudiaremos, pero también se puede extrapolar a otro tipo de empresas. Nos enfocaremos en cinco gigantes tecnológicos: Apple, Tesla, Google, Microsoft y Amazon, cuyos movimientos en el mercado no solo impactan a la industria, sino que también reflejan tendencias más amplias en la economía global. Al examinar la aplicación de la inteligencia artificial en este contexto, buscamos entender cómo estas innovadoras técnicas pueden mejorar la precisión y la fiabilidad de las predicciones financieras, ofreciendo así un valioso recurso para aquellos que buscan tomar decisiones informadas en el competitivo mundo de las inversiones.

II. MARCO TEÓRICO

El presente trabajo se centra en la predicción del precio de acciones de 5 empresas líderes en tecnología, como los son, Apple, Tesla, Google, Microsoft y Amazon. Todo esto utilizando redes neuronales recurrentes trabajando principalmente con la librería TensorFlow en conjunto con Keras en Python. Antes de pasar a la metodología y resultados hace falta explicar conceptos claves, que son los siguientes:

A. Acciones

Las acciones son un instrumento de participación en la propiedad de una empresa. En particular, una acción representa la participación mínima en que se divide el capital de una empresa o sociedad.

Al comprar acciones, te conviertes en propietario de una fracción de la empresa. De esta forma, pasas a formar parte del capital social de la sociedad y adquieres determinados derechos económicos y financieros. Esto lo utilizan las empresas como una estrategia para recaudar fondos e invertirlos para elevar el valor total de esta.

El precio de las acciones no es estático y suele variar en el tiempo dependiendo de la inversión del dinero y del comportamiento del mercado, algunos de los factores que influyen en el precio de las acciones son, oferta y demanda, ya que a mayor cantidad de interesados de adquirir acciones mayor es el precio de estas, también está el beneficio esperado, ya que esto es una inversión, por lo que a mayor beneficio esperado al comprar acciones mayor es el precio de estas y otro factor clave es el sentimiento, el cual se refiere a la proyección del comportamiento de las acciones del mercado y esto define la tendencia y las expectativas que se tienen de las acciones, y esto es justamente lo que analizaremos en este proyecto.

B. Redes Neuronales Recurrentes

Una red neuronal recurrente (RNN) es un tipo de red neuronal artificial diseñada para manejar datos secuenciales o de series temporales. A diferencia de las redes neuronales convolucionales (CNN) y las redes de

propagación hacia delante, las RNN destacan por su capacidad para recordar información de entradas anteriores, lo que las hace especialmente útiles en problemas temporales. Estas redes son comúnmente utilizadas en aplicaciones como la traducción de idiomas, procesamiento del lenguaje natural (NLP), reconocimiento de voz y subtítulos de imágenes, y se integran en tecnologías populares como Siri, búsqueda de voz y Google Translate.

En el contexto de la predicción de acciones, las RNN pueden ser aplicadas para modelar patrones complejos en datos históricos de precios. A través de su capacidad para capturar dependencias a largo plazo, las RNN pueden aprender y entender las relaciones entre las fluctuaciones pasadas de los precios de las acciones. A diferencia de las redes neuronales convencionales, las RNN consideran la secuencia temporal de los datos, permitiendo que la información de entradas anteriores influya en las predicciones actuales. Esta característica es crucial en la predicción de acciones, ya que los movimientos pasados del mercado a menudo tienen un impacto significativo en las tendencias futuras.

Es importante destacar que, si bien las RNN unidireccionales no pueden anticipar eventos futuros en sus predicciones, su capacidad para aprender y recordar patrones temporales las hace valiosas para capturar la complejidad inherente a la dinámica del mercado de valores. La aplicación de RNN en la predicción de acciones ofrece una perspectiva avanzada y más precisa, ya que tiene en cuenta la naturaleza secuencial de los datos financieros.

C. TensorFlow y Keras

TensorFlow es una biblioteca de software de código abierto diseñada para facilitar la implementación de modelos de aprendizaje automático y deep learning. Proporciona herramientas y recursos para construir y entrenar redes neuronales, así como para realizar otras tareas de machine learning.

Keras es una API de alto nivel, para redes neuronales escrita en Python. Se trata de una biblioteca de código abierto que se ejecuta sobre frameworks como TensorFlow. Keras con Tensorflow permite crear modelos de aprendizaje automático de una forma mucho más simple y rápida, sin meternos con código complejo de bajo nivel, lo que nos es de mucha ayuda a la hora de crear redes neuronales recurrentes para la predicción del precio de acciones que estudiaremos.

III. METODOLOGÍA

La metodología utilizada para este estudio se dividió en dos partes, la primera consistió en el preprocesamiento y análisis exploratorio de los datos, y la segunda parte consistió en el entrenamiento de un predictor de precios de acciones, usando métodos de Deep Learning.

A. Preprocesamiento y análisis exploratorio de los datos

Para esta primera parte del trabajo, iniciamos cargando las bases de datos con la información de los precios de las acciones de las 5 empresas que estamos estudiando, y utilizaremos los datos desde el 01-01-2015 hasta el 26-02-2021, es decir más de 6 años de registros de precios de acciones. Una vez cargadas las bases, verificamos que los datos que sean numéricos estén en tipo numéricos y los datos de tipo objeto estén en este tipo, esto lo hacemos con .info que nos muestra esta información de cada columna, otra cosa importante antes de empezar a generar las visualizaciones es eliminar las filas que tengan datos faltantes, ya que estos pueden generar errores a la hora de trabajar los datos, esto lo hacemos con .dropna, que elimina las filas que tengan valores con NA, como último paso de preprocesamiento de los datos, tenemos el de usar como índice la fecha para así poder trabajar los datos de mejor manera, para esto debemos cambiar el Dtype de la columna fecha a datetime y asignarla al índice. Todos estos pasos se pueden ver en los siguientes códigos:

```
AAPL.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9800 entries, 0 to 9799
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Date        9800 non-null   object
1   Open        9800 non-null   object
2   High        9725 non-null   float64
3   Low         9725 non-null   float64
4   Close       9725 non-null   float64
5   Adj. Close  9725 non-null   float64
6   Volume      9725 non-null   object
dtypes: float64(4), object(3)
memory usage: 536.1+ KB

# Drop NULL rows
AAPL.dropna(inplace = True)

# Change Dtype of Columns
AAPL["Date"] = pd.to_datetime(AAPL["Date"])
AAPL["Volume"] = AAPL["Volume"].str.replace(',', '')
AAPL = AAPL.astype({"Open": float, "Volume": float})

# Sort the Database by Date
AAPL = AAPL.sort_values(by = 'Date', ignore_index = True)

# Drop rows having Date < '2015-01-01'
AAPL = AAPL[AAPL["Date"] >= '2015-01-01'].reset_index(drop = True)
```

Tal como se ve en la imagen, esto es aplicado a la base de datos de Apple, pero para las demás bases es el mismo código, solo se debe cambiar el nombre de la base de datos de Apple por la que se quiera utilizar.

Una vez hecho el preprocesamiento de los datos, pasamos al análisis exploratorio de estos, para esto lo que se hizo fue graficar el comportamiento del precio de cierre de las acciones, el volumen de acciones negociadas cada día, el promedio móvil de las distintas acciones, la rentabilidad diaria promedio y la correlación entre el precio de cierre de las acciones de las diferentes compañías. Todo esto se hizo utilizando la librería matplotlib para graficar, a excepción de los gráficos de correlación que se usó la librería seaborn.

B. Entrenamiento del predictor de precios de acciones

Para la parte 2 y final de este proyecto lo que se hizo fue crear el predictor de precios de acciones, para esto se inició cargando las bases de datos de las acciones de las 5 empresas, pero esta vez con los datos ya preprocesados del paso anterior, para no tener que repetir lo mismo y ahorrar tiempo. Una vez cargadas las bases lo que se realizó fue separar los datos en datos de entrenamiento (02-01-2015 - 30-09-2020) y de prueba (01-10-2020 – 26-02-2021), para así poder evaluar los resultados que obtendremos con el predictor.

Luego de esto definimos el modelo, utilizando TensorFlow y Keras, creamos un modelo de red neuronal recurrente de Memoria a corto-largo plazo (LSTM) con 2 capas seguidas de varias capas totalmente conectadas, todas ellas utilizando la función de activación leaky_relu, el cual tiene la siguiente estructura:

Model: "sequential"

Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 5, 200)	161600
lstm_1 (LSTM)	(None, 200)	320800
dense (Dense)	(None, 200)	40200
dense_1 (Dense)	(None, 100)	20100
dense_2 (Dense)	(None, 50)	5050
dense_3 (Dense)	(None, 5)	255

Luego de esto ajustamos el modelo, indicando el optimizador a utilizar, el cual es Adam, la función de pérdida, que en este caso es 'mse' que calcula el error cuadrático medio, es decir, compara el valor que predice el modelo con el valor real. Luego se realiza el entrenamiento del modelo. Donde se utilizan los datos de entrenamiento, se especifica el número de épocas, y se utiliza los datos de prueba para evaluar el rendimiento, además se emplea un callback para detener el entrenamiento en caso de que no se observe mejora.

Ya teniendo el modelo definido, se procede a aplicarlo a los datos de las 5 empresas, para luego graficar los resultados y realizar el análisis correspondiente. Al igual que en el análisis exploratorio, aquí igual se utiliza la librería matplotlib para realizar los gráficos.


IV. RESULTADOS


A. Preprocesamiento y análisis exploratorio de los datos

Tal como se puede apreciar en los gráficos correspondientes a los precios de cierre de las acciones, en todas las empresas podemos ver un crecimiento progresivo de los precios desde el año 2015 al 2021, a simple vista la que mayor crecimiento tuvo fue Tesla, que pese a ser la única empresa fundada en este siglo, concretamente el


2003, entró a la bolsa el año 2010, desde 2015 a 2021 tuvo un crecimiento en el valor de sus acciones en más de un 800%, teniendo su boom entre el año 2020 y 2021, lo que es curioso ya que fue el año de la pandemia por covid-19, algunos de los motivos de este fenómeno pueden ser, la venta de créditos de emisiones a otras compañías de vehículos, ya que en 2020 las empresas no podían producir demasiado debido al confinamiento que había, Tesla se centró en vender créditos de emisiones, que son una suerte de "licencia para contaminar", por la que se compensan los excesos de unos con las cero emisiones de otros. Esto lo pudo hacer Tesla ya que a ellos les sobraban debido a que se dedican a la fabricación de vehículos eléctricos por lo que la emisión de dióxido de carbono de sus vehículos es prácticamente 0.

Las demás empresas tampoco se quedan atrás en el crecimiento del precio de sus acciones, y esto se debe a que como son todas compañías de un mercado en constante crecimiento en la última década, y esto hace que haya una mayor demanda por las acciones de compañías de este sector y por ello el precio ha aumentado tan bruscamente.





En cuanto a la correlación de los precios de cierre de las acciones de estas compañías, tenemos el siguiente grafico:




En donde vemos que las empresas con mayor correlación son, Microsoft con Amazon, con un 0.98 de correlación entre los precios de sus acciones, seguidas de cerca por, Google con Amazon (0.96 de correlación), Google con Microsoft (0.96 de correlación) y Apple con Microsoft (0.96), básicamente la empresa con mayor correlación en el precio de sus acciones con las demás es Microsoft. Por otro lado, la empresa con menor correlación con las demás es Tesla, que con ninguna supera el 0.88, esto se puede deber a que, si bien esta en el mercado de la tecnología, ofrece un producto muy distinto a


las demás, ya que vende vehículos eléctricos, y las demás venden productos como celulares, software, etc... que están más relacionados entre sí.

B. PREDICTOR DE PRECIOS DE ACCIONES

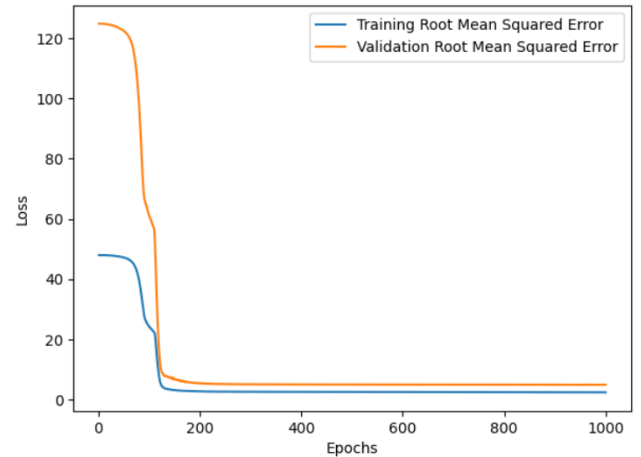

Ya que tenemos los resultados reales de los precios de las acciones y su respectivo análisis, podemos centrarnos en los resultados del predictor. En los gráficos podemos ver en azul los datos de entrenamiento, que son los reales, que también vimos en la primera parte, luego en naranja tenemos los datos de prueba, que son los datos reales que son comparados con los de predicción, que están en verde.

Tal como podemos ver, las predicciones son muy similares a los valores reales, prácticamente la línea verde de las predicciones se sobrepone a las naranjas de los datos de prueba que son los reales, por lo cual el modelo fue un éxito y se podría implementar para ver acciones en periodos futuros.





Esto también está respaldado por la comparación entre el los de validación y entrenamiento, además por el error cuadrático medio, en donde la diferencia se hace prácticamente nula, lo que significa que el predictor está funcionando bien, esto lo podemos ver en los siguientes gráficos de Apple:



Para ver los gráficos de las demás compañías se debe ejecutar el código, pero prácticamente en todos la diferencia es mínima, por lo que el predictor funciona.

V. DISCUSIÓN

Tal como se pudo ver en el análisis de los resultados, el predictor funcionó perfectamente, la

aplicación de inteligencia artificial en el ámbito financiero ha generado gran interés en el último tiempo, y sin duda se utilizará de parte de los inversionistas y las empresas, quienes sin duda lo utilizarán para mejorar el mercado. La implementación de una red neuronal recurrente (RNN) basada en capas de memoria a largo plazo (LSTM) fue un éxito para predecir los precios de acciones de las compañías.

Los resultados obtenidos revelan la capacidad de la red neuronal recurrente propuesta para capturar patrones temporales complejos en los datos históricos de precios de acciones. La elección de utilizar capas LSTM resultó ser acertada, ya que estas permiten a la red aprender dependencias a largo plazo, lo que es esencial en un entorno financiero donde las tendencias a menudo se extienden más allá de las observaciones inmediatas.

VI. CONCLUSIONES GENERALES

Los resultados obtenidos y las observaciones realizadas nos permiten llegar a diversas conclusiones generales:

- A. Éxito en la Predicción: La red neuronal recurrente ha demostrado ser un enfoque eficaz para la predicción de precios de acciones. La utilización de capas LSTM ha permitido al modelo capturar patrones complejos y dependencias temporales, lo que se traduce en predicciones precisas en el conjunto de prueba.
- B. Prevención de Sobreajuste: La evaluación en un conjunto de prueba ha indicado que el modelo no ha caído en el sobreajuste. La red ha logrado generalizar a datos no utilizados durante el entrenamiento, lo que indica su capacidad para manejar nuevas observaciones de manera efectiva.
- C. Potencial para Decisiones Financieras: Los resultados obtenidos sugieren que la red neuronal recurrente podría ser una herramienta valiosa en el proceso de toma de decisiones financieras. Sin embargo, hay que considerar estos resultados como un complemento a otras fuentes de información y análisis.
- D. Áreas de Mejora y Desarrollo Futuro: A pesar de los resultados prometedores, se reconocen áreas de mejora potencial. La optimización de hiperparámetros, la exploración de arquitecturas más avanzadas y la inclusión de características adicionales podrían elevar aún más la precisión del modelo.
- E. Apertura a Investigaciones Adicionales: Este estudio sienta las bases para investigaciones adicionales en el ámbito de la predicción de precios de acciones mediante inteligencia artificial. La experimentación con enfoques innovadores, la inclusión de datos adicionales y la validación en diferentes entornos del mercado podrían enriquecer y ampliar aún más el campo.

VII. BIBLIOGRAFÍA

- A. [¿Qué son las acciones de una empresa? Definición, tipos, características | Rankia](#)
- B. [LSTM para la predicción del precio de las acciones \(ichi.pro\)](#)
- C. [¿Qué son las redes neuronales recurrentes? | IBM](#)
- D. [Tesla prosperó mientras Ford y GM tuvieron problemas - The New York Times \(nytimes.com\)](#)
- E. [Tesla obtiene sus mayores beneficios de... ¡la contaminación! - HackerCar](#)